재활용 폐플라스틱 가격 시계열 분석

김서윤[1], 정선우[1]

요약

본 연구는 2003년 1월부터 2025년 1월까지의 국내 재활용 폐플라스틱 평균 가격 데이터를 바탕으로 시계열 분석을 수행하고, 2025년 향후 가격 변동을 예측하고자 하였다. 분석에 앞서 로그 변환을 통해 분산의 안정성을 확보하고, 1차 차분을 통해 정상성을 만족하였다. 이후 식별된 ARIMA 모형군을 비교한 결과, ARIMA(0,1,2) 로그 모형이 AIC 기준으로 가장 우수한 성능을 보여 최종 모형으로 선정되었다. 모형 진단 결과, 잔차는 백색잡음의 특성을 만족하였으며, 모든 모수는 통계적으로 유의하여 해당 모형의 적합성을 확인하였다.

최종적으로 선정된 ARIMA(0,1,2) 모형을 활용하여 2025년 2월부터 12월까지의 월별 가격을 예측한 결과, 재활용 폐플라스틱 가격은 전반적으로 완만한 상승세를 보일 것으로 나타났다. 이는 재활용 원가 상승 및 자원 수급 구조 변화 가능성과 관련된 것으로 보인다. 그러나 잔차 분석에서는 일부 시점에서 이상치 및 잔존 자기상관이 관측되어 모형의 보완 가능성도 함께 제기되었다. 본 연구는 재활용 자원의 가격 예측을 통해 자원 관리 및 환경 정책 수립에 있어 실증적 근거를 제공하고, 순환경제 실현을 위한 전략 마련에 기여할 수 있을 것으로 기대된다.

주요용어 : 폐플라스틱, ESG, 순환경제

1. 서론

인간의 모든 경제활동은 자원의 소비와 직결되며, 이는 환경과 사회 전반에 중대한 영향을 미친다. 특히 최근에는 순환경제와 ESG(Environmental, Social and Governance) 가치가 부각되면서, 자원 절약과 재활용의 중요성이 강조되고 있다. 자원순환경제는 자원절약과 재활용 등을 통해 지속가능한 환경을 추구하는 경제모델의 대안으로 기후변화에 대한 해결책 중 하나의 방안으로 제시하고 있다(최다연 외, 2024). 이러한 맥락에서 플라스틱은 사용량이 많고 환경에 미치는 영향이 크기 때문에, 순환경제 실현에 있어 핵심적인 소재로 간주된다. 특히 플라스틱은 가볍고 가공이 용이하여 산업 전반에 걸쳐 폭넓게 사용되고 있으나, 사용 이후의 폐기 문제와 미세플라스틱에 따른 생태계 오염 문제 등 다양한 환경적 부담을 유발한다. 이에 따라 재활용 가능한 폐플라스틱의 수거 및 처리, 재생산을 촉진하기 위한 정책적, 산업적 대응이 활발히 이루어지고 있으며, 이러한 흐름 속에서 재활용 플라스틱의 가격 변동은 순환경제의 활성화 수준과 정책 효과성을 가늠할 수 있는 중요한 척도로 작용한다. 본 연구는 재활용 플라스틱이라는 핵심 자원의 가격 데이터를 분석하고, 향후 가격 변동을 예측함으로써 자원 시장의 구조적 이해를 도모하고 정책 수립에 활용 가능한 통계적 통찰을 제시하고자 한다. 분석에 사용된 데이터는 2003년 1월부터 2025년 1월까지의 전국 재활용 폐플라스틱 평균 가격(단위: 원/kg)이며, 시계열적 특성을 고려하여 월별 단위로 구성된 자료를 바탕으로 분석을 진행하였다. 본 분석에서는 시계열 데이터의 정상성 여부 판단, 추세 및 구조 분석, 적절한

1) 자연과학대학 정보통계학과

ARIMA 계열 모형 선정, 예측력 평가 등을 통해 실증적인 결론을 도출하고자 한다. 나아가, 분석 결과는 순환경제 전략 수립, 재활용 산업 지원 정책, 탄소중립 전환에 따른 가격 민감도 평가 등 다양한 분야에 실질적인 시사점을 제공할 수 있을 것이다.

2. 모형추정

2.1 데이터 분석

시계열 모형의 효과적인 식별 및 추정을 위해서는 데이터의 평균, 분산, 그리고 주기성과 같은 구조적 특성을 파악해야 한다. 특히, 시계열 모형은 데이터의 정상성을 전제로 하기 때문에 원시 시계열 데이터의 평균과 분산이 시간에 따라 일정하게 유지되는지 분석하고 주기성 여부를 확인하였다. 먼저 데이터의 대략적인 추세를 보기 위해 <그림1>은 원시 데이터에 대한 시계열 그래프이다. 이를 통해 데이터의 시간의 흐름에 따라 장기적인 상승 추세가 존재함을 확인하였고, 분산은 비교적 일정하게 유지되는 것으로 나타났다. 이는 재활용 플라스틱 가격이 시간에 따라 평균적으로 점진적으로 상승하는 경향을 보이지만, 가격 변동 폭 자체는 비교적 일정하게 유지된다는 것을 의미한다.

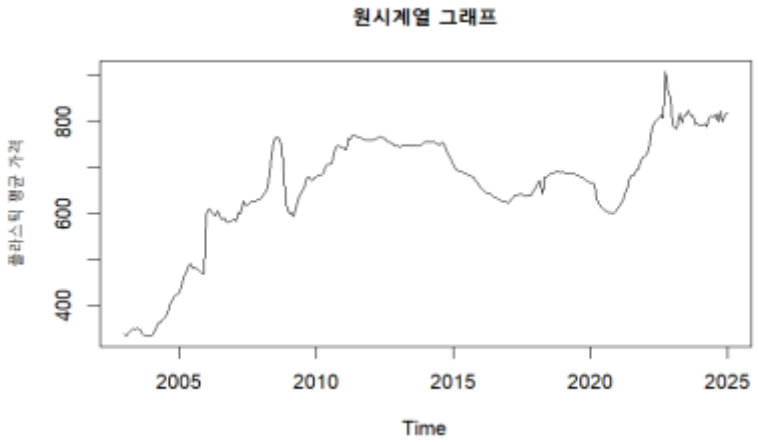

<그림 1> 원데이터의 시계열 그림

2.2 정상성 검정

적절한 시계열 모형 식별을 위해 원데이터의 자기상관함수(ACF)와 부분자기상관함수(PACF)를 활용하여 시계열의 시차별 의존 구조를 분석하였다. ACF는 전체 시계열에서 일정 시차만큼 떨어진 값들 간의 상관관계를 나타내며, PACF는 중간 시차의 영향을 통제한 상태에서의 순수한 시차 간 상관관계를 보여준다. 이 두 함수는 AR, MA 및 ARMA 계열 모형의 적절한 차수를 결정하고, 시계열 모형을 효과적으로 식별하기 위한 필수적인 분석 과정이다. <그림 2>의 ACF를 보면, 서서히 감소하는 형태를 보여 비정상성 시계열임을 확인할 수 있다. 또한, 시차 12개월 단위의 반복적인 패턴이 관측되지 않아 월별 계절성이 존재하지 않는다고 판단하였다. 이에 따라 정상성을 확보하기 위해 1차 차분이 필요하다고 판단하였고, 보다 안정적인 분산과 향상된 예측력을 확보하고자 로그 변환을 추가로 수행하였다. <그림 3>의 로그 변환 후 1차 차분한 시계열 그래프를 보면 어떠한 추세나 계절성도 보이지 않고 랜덤한 형태의 산포를 보이므로 정상성을 만족한다.

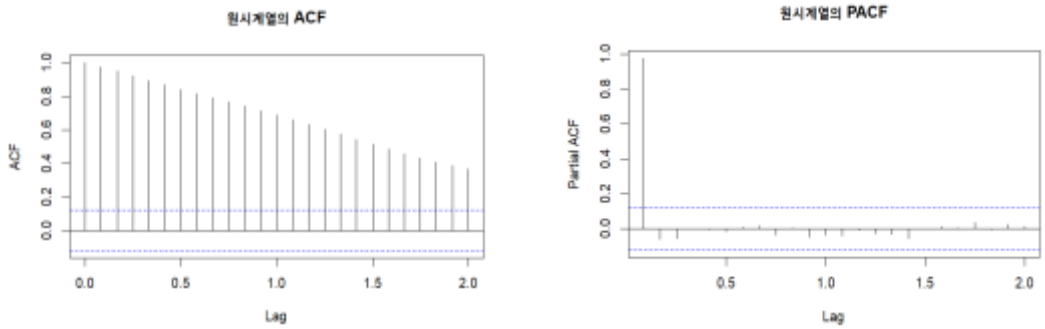

<그림 2> 원데이터의 ACF와 PACF

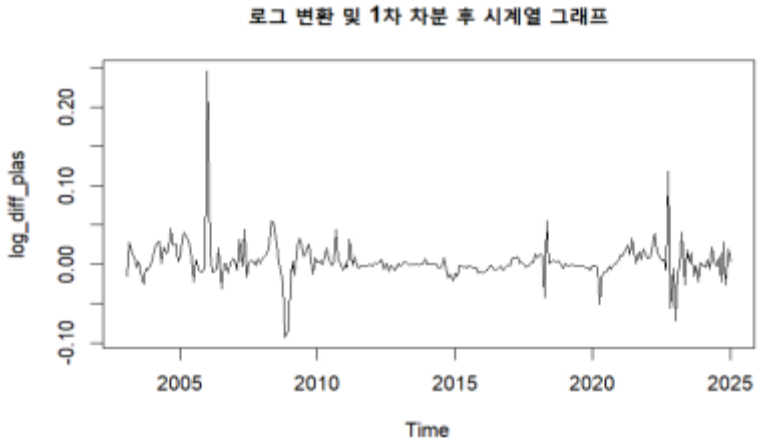

<그림 3> 로그변환 후 1차 차분한 시계열 그림

2.3 모형 식별

<그림 4>는 로그 변환 후 1차 차분한 시계열의 ACF 및 PACF 그래프를 나타낸 것이다. ACF에서는 시차 1에서 뚜렷한 양의 자기상관이 공통적으로 관측되며, 이는 시계열 자료의 시간적 연속성에 따른 일반적인 특성으로 해석된다. 따라서 모형 식별을 위해 시차 2 이후의 구조를 살펴본 결과, 시차 2부터는 자기상관이 급격히 감소하여 대부분의 시차가 신뢰구간 내에 위치하는 양상을 보였다. 이는 자기상관이 짧은 시차에서만 유의하게 나타나며 이후 빠르게 소멸하는 형태로, MA(1) 또는 MA(2) 모형을 고려할 수 있다.

PACF 그래프 또한 시차 2에서 절단되는 패턴을 보였으며, 시차 3 이후에는 유의한 부분자기상관이 나타나지 않았다. 이에 따라 해당 시계열은 AR(2) 모형으로 식별되었다. 이러한 결과를 종합하면 ACF와 PACF 모두 짧은 시차에서 절단되는 특성을 보이며, 이를 바탕으로 ARIMA(2,1,2)를 포함한 다양한 ARIMA 모형을 후보로 설정하고 적합도를 비교하여 최적 모형을 선정하고자 한다.

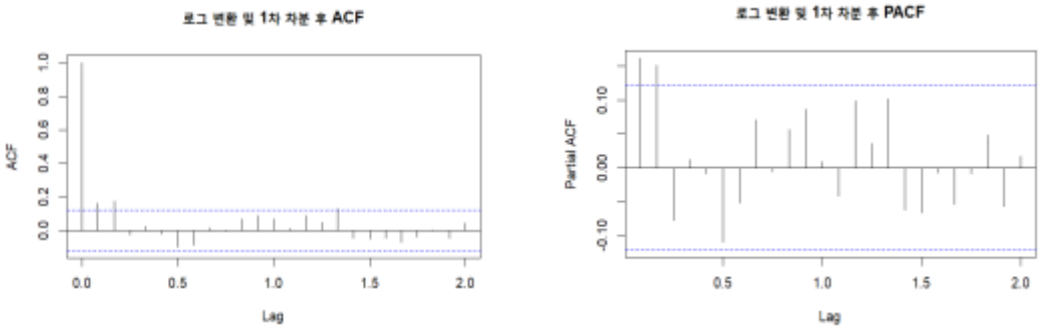

<그림 4> 로그변환 후 1차 차분한 ACF와 PACF

3. 모형 진단 및 선정

3.1 모형 진단

본 연구에서는 시계열 데이터에 가장 적합한 모형을 찾아내기 위해 여러 후보 모형들을 검토하고 모형 진단을 실시하였다. 모형의 적합도를 평가하고 최적의 모형을 선택하기 위해 주어진 모형이 관측된 데이터를 얼마나 잘 설명하는지를 나타내는 지표인 로그-우도(Log-Likelihood)와, 모형의 적합도와 복잡도를 동시에 고려하여 과적합을 방지하고 예측 성능이 우수한 모형을 선택하게 돕는 AIC(Akaike Information Criterion)를 활용하였다. 또한, 각 모형의 계수 유의성을 Z-검정으로 검토하고, 모형 적합 후 잔차에 유의미한 자기상관이 남아있는지 여부를 판단하기 위해 Ljung-Box 검정(퍼트맨토우 검정)을 수행하였다.

먼저 ARIMA(0,1,2) 모형을 검정하였다. 이 모형은 1차 차분된 이동평균 2차(MA(2)) 모델로 구성되었다. 모형의 적합도 지표를 살펴보면, 로그-우도(Log-Likelihood)는 611.82, AIC(Akaike Information Criterion)는 -1217.64로 나타났다.

이어서 모형의 계수 유의성을 검정하기 위해 Z-검정을 수행하였다. <표 1>은 이에 대한 결과로, 모든 이동평균(MA) 계수들이 통계적으로 유의미한 것을 보여준다.($p < 0.01$). 구체적으로, MA(1) 계수는 0.1683 (표준 오차=0.0619, z값=2.72, p=0.0066)으로 나타났으며, MA(2) 계수는 0.1886 (표준 오차=0.0581, z값=3.25, p=0.0012)으로 나타났다. 이는 시계열 데이터의 예측에 있어 이전 시점의 예측 오차가 유의미한 영향을 미침을 시사한다. 잔차 분산은 0.0005681로 추정되었다.

<표 1> ARIMA(0,1,2) 모형에 대한 계수 추정 및 유의성 검정 결과

	Estimate	std.Error	Z value	Pr(>|z|)	
MA(1)	0.168266	0.061938	2.7167	0.006594	**
MA(2)	0.188579	0.058109	3.2453	0.001173	**

적합된 ARIMA(0,1,2) 모형의 적절성을 평가하기 위해 잔차에 대한 Ljung-Box 검정을 수행하였다. Ljung-Box 검정은 모형 잔차에 유의미한 자기상관이 남아있는지 여부를 판단하여, 모형이 시계열의 패턴을 충분히 설명했는지 검증한다. 검정은 다양한 시차(6, 12, 18, 24, 30, 36)에서 이루어졌으며, 그 결과는 <표 2>와 같다. 검정 결과, 모든 시차에서 계산된 p-값은 0.05보다 크게 나타났다. 이는 5% 유의수준에서 귀무가설, 즉 잔차에 유의미한 자기상관이 없다는 가설을 기각할 수 없음을 의미한다. 따라서, ARIMA(0,1,2) 모형의 잔차는 백색 잡음의 특성을 보이며, 이는 해당 모형이 적절하다는 것을 의미한다.

<표 2> ARIMA(0,1,2)의 Ljung-Box 결과

lags	statistic	df	p-value
6	3.857101	4	0.4256904
12	8.711772	10	0.5596585
18	17.357598	16	0.3628298
24	20.105116	22	0.5764645
30	21.39383	28	0.8085523
36	29.848587	34	0.6713748

다음으로는 ARIMA(1,1,1) 모형을 검정하였다. 이 모형은 1차 차분된 자기회귀 1차(AR(1)) 및 이동평균 1차(MA(1)) 모델로 구성되었다. 모형의 로그-우도(Log-Likelihood)는 609.75, AIC(Akaike Information Criterion)는 -1213.51로 나타났다.

모형의 계수 유의성을 검정하기 위해 Z-검정을 수행한 결과는 <표 3>에서 볼 수 있으며, 모든 계수가 통계적으로 유의미한 것으로 나타났다. 구체적으로, 자기회귀 1차(AR(1)) 계수는 0.5730 (표준 오차=0.1651, z값=3.47, p<0.001)으로 매우 유의미하게 나타났으며, 이동평균 1차(MA(1)) 계수는 -0.3969 (표준 오차=0.1810, z값=-2.19, p<0.05)로 유의미하게 나타났다. 이는 이전 시점의 데이터와 예측 오차가 현재 시점의 데이터 예측에 유의미한 영향을 미침을 시사한다. 잔차 분산은 0.0005771로 추정되었다.

<표 3> ARIMA(1,1,1) 모형에 대한 계수 추정 및 유의성 검정 결과

	Estimate	std.Error	Z value	Pr(>|z|)	
AR(1)	0.57299	0.16505	3.4715	0.0005176	***
MA(1)	-0.39692	0.18104	-2.1924	0.0283493	**

적합된 ARIMA(1,1,1) 모형의 잔차가 백색 잡음 특성을 갖는지 확인하기 위해 Ljung-Box 검정을 다양한 시차(6, 12, 18, 24, 30, 36)에서 수행하였다. 검정 결과는 <표 4>에서 볼 수 있듯이, 모든 시차에서 p-값은 0.05보다 크게 나타났다. 이는 잔차에 통계적으로 유의미한 자기상관이 남아있지 않음을 의미하며, ARIMA(1,1,1) 모형이 시계열 데이터의 패턴을 정상적으로 설명하고 있음을 보여준다.

<표 4> ARIMA(1,1,1)의 Ljung-Box 결과

lags	statistic	df	p-value
6	7.714724	4	0.1026052
12	12.697187	10	0.2410986
18	21.800004	16	0.1497673
24	24.964295	22	0.2987853
30	26.190884	28	0.5625529
36	33.703488	34	0.4820725

세 번째로 ARIMA(1,1,2) 모형을 검정하였다. 이 모형은 1차 차분된 자기회귀 1차(AR(1)) 및 이동평균 2차(MA(2)) 모델로 구성되었다. 모형의 로그-우도(Log-Likelihood)는 612.18, AIC(Akaike Information Criterion)는 -1216.35로 나타났다. 로그-우도는 이전 모형들(ARIMA(0,1,2): 611.82, ARIMA(1,1,1): 609.75)보다 높게 나타났으나, AIC 값은 ARIMA(0,1,2)의 -1217.64보다는 높고, ARIMA(1,1,1)의 -1213.51보다는 낮아, 적합도와 복잡

도를 종합적으로 고려할 때 중간 수준의 성능을 보였다.

모형의 계수 유의성을 검정하기 위해 Z-검정을 수행한 결과, <표 5>에서 보는 것처럼 자기회귀 1차(AR(1)) 계수는 -0.2620 (표준 오차=0.2481, z값=-1.06, p=0.2910)으로 통계적으로 유의미하지 않다. 이동평균 1차(MA(1)) 계수는 0.4250 (표준 오차=0.2427, z값=1.75, p=0.0799)으로 5% 유의수준에서는 유의미하지 않았으나 10% 유의수준에서는 유의미한 경향을 보였다. 반면, 이동평균 2차(MA(2)) 계수는 0.2342 (표준 오차=0.0684, z값=3.42, p<0.001)로 0.1% 유의수준에서 통계적으로 매우 유의미한 것으로 나타났다. 잔차 분산은 0.0005665로 추정되었다.

<표 5> ARIMA(1,1,2) 모형에 대한 계수 추정 및 유의성 검정 결과

	Estimate	std.Error	Z value	Pr(>|z|)	
AR(1)	-0.262026	0.248132	-1.0560	0.29097	
MA(1)	0.424994	0.242656	1.7514	0.07987	*
MA(2)	0.234222	0.068431	3.4227	0.00062	***

적합된 모형의 잔차가 백색 잡음 특성을 갖는지 확인하기 위해 Ljung-Box 검정을 다양한 시차에서 수행하였다. 검정 결과는 <표 6>에서 볼 수 있듯이, 모든 시차(6, 12, 18, 24, 30, 36)에서 p-값은 0.05보다 크게 나타났다. 이는 잔차에 통계적으로 유의미한 자기상관이 남아 있지 않음을 의미하며, ARIMA(1,1,2) 모형이 시계열 데이터의 자기상관 구조를 적절히 포착했음을 알 수 있다. 그러나 AR(1) 계수와 MA(1) 계수의 비유의성은 모형의 간결성 측면에서 재고할 필요성이 있음을 시사한다.

<표 6> ARIMA(1,1,2)의 Ljung-Box 결과

lags	statistic	df	p-value
6	3.030502	3	0.3869462
12	8.118115	9	0.5222884
18	16.619462	15	0.3421170
24	19.749022	21	0.5372046
30	20.979201	27	0.7872615
36	29.117324	33	0.6609522

네 번째는 ARIMA(2,1,0) 모형을 검정한 결과이다. 이 모형은 1차 차분된 자기회귀 2차(AR(2)) 모델로 구성되었다. 모형의 로그-우도(Log-Likelihood)는 611.42, AIC(Akaike Information Criterion)는 -1216.85로 나타났다.

모형의 계수 유의성을 검정하기 위해 Z-검정을 수행한 결과는 <표 7>에서 볼 수 있다. 자기회귀 1차(AR(1)) 계수는 0.1477 (표준 오차=0.0606, z값=2.43, p=0.0149)로 5% 유의수준에서 유의미하게 나타났다. 자기회귀 2차(AR(2)) 계수는 0.1612 (표준 오차=0.0608, z값=2.65, p=0.0080)로 1% 유의수준에서 통계적으로 유의미한 것으로 나타났다. 이는 이전 두 시점의 데이터가 현재 시점의 데이터 예측에 유의미한 영향을 미침을 시사한다. 잔차 분산은 0.0005698로 추정되었다.

<표 7> ARIMA(2,1,0) 모형에 대한 계수 추정 및 유의성 검정 결과

	Estimate	std.Error	Z value	Pr(>|z|)	
AR(1)	0.147658	0.060647	2.4347	0.014904	*
AR(2)	0.161240	0.060796	2.6521	0.007998	**

적합된 모형의 잔차가 백색 잡음 특성을 갖는지 확인하기 위해 Ljung-Box 검정을 다양한 시차에서 수행하였다. 검정 결과는 <표 8>에서 볼 수 있듯이, 모든 시차(6, 12, 18, 24, 30, 36)에서 p-값은 0.05보다 크게 나타났다. 이는 잔차에 통계적으로 유의미한 자기상관이 남아 있지 않음을 의미하며, ARIMA(2,1,0) 모형이 시계열 데이터의 자기상관 구조를 성공적으로 설명하고 있음을 보여준다.

<표 8> ARIMA(2,1,0)의 Ljung-Box 결과

lags	statistic	df	p-value
6	4.588178	4	0.3322196
12	9.528357	10	0.4827986
18	18.424239	16	0.2996461
24	21.120741	22	0.5132871
30	22.322254	28	0.7661581
36	31.384498	34	0.5964663

다섯 번째로 ARIMA(2,1,1) 모델을 검정한 결과이다. 이 모델은 1차 차분된 자기회귀 2차 및 이동평균 1차 모델로 구성되었다. 모델의 로그-우도(Log-Likelihood)는 612.04, AIC(Akaike Information Criterion)는 -1216.08로 나타났다.

모델의 계수 유의성을 검정하기 위해 Z-검정을 수행한 결과는 <표 9>에서 볼 수 있다. 자기회귀 1차(AR(1)) 계수(-0.1918, p=0.4695)와 이동평균 1차(MA(1)) 계수(0.3496, p=0.1947)는 통계적으로 유의미하지 않았다. 반면, 자기회귀 2차(AR(1)) 계수는 0.2243 (표준 오차 =0.0670, z값=3.35, p<0.001)으로 0.1% 유의수준에서 통계적으로 매우 유의미한 것으로 나타났다. 잔차 분산은 0.0005671로 추정되었다.

<표 9> ARIMA(2,1,1) 모형에 대한 계수 추정 및 유의성 검정 결과

	Estimate	std.Error	Z value	Pr(>|z|)	
AR(1)	-0.191774	0.265142	-0.7233	0.4695046	
AR(2)	0.224251	0.066977	3.3482	0.0008134	***
MA(1)	0.349605	0.269573	1.2969	0.1946710	

적합된 모델의 잔차가 백색 잡음 특성을 갖는지 확인하기 위해 Ljung-Box 검정을 다양한 시차에서 수행하였다. 검정 결과는 <표 10>에서 볼 수 있듯, 모든 시차(6, 12, 18, 24, 30, 36)에서 p-값은 0.05보다 크게 나타났다. 이는 잔차에 통계적으로 유의미한 자기상관이 남아 있지 않음을 의미하며, ARIMA(2,1,1) 모델이 시계열 데이터의 자기상관 구조를 적절히 포착했음을 지지한다. 그러나 AR(1)과 MA(1) 계수의 통계적 비유의성은 모델의 간결성 측면에서 재고가 필요할 수 있다.

<표 10> ARIMA(2,1,1)의 Ljung-Box 결과

lags	statistic	df	p-value
6	3.670661	3	0.2992930
12	8.449303	9	0.4895762
18	17.148233	15	0.3100806
24	20.160300	21	0.5111289
30	21.372635	27	0.7685326
36	29.892074	33	0.6226466

마지막 모형은 ARIMA(2,1,2) 이다. 이 모델은 1차 차분된 자기회귀 2차 및 이동평균 2차로 구성되었다. 모델의 로그-우도(Log-Likelihood)는 612.18, AIC(Akaike Information Criterion)는 -1214.35로 나타났다.

모델의 계수 유의성을 검정하기 위해 Z-검정을 수행한 결과는 <표 11>에서 볼 수 있으며, 모든 계수들이 통계적으로 유의미하지 않은 것으로 확인되었다. 자기회귀 1차(AR(1)) 계수는 -0.2501 (p=0.4855), 자기회귀 2차(AR(2)) 계수는 0.0247 (p=0.9632), 이동평균 1차(MA(1)) 계수는 0.4129 (p=0.2470), 이동평균 2차(MA(2)) 계수는 0.2090 (p=0.7034)으로 나타났다. 모든 계수의 p-값이 0.05보다 커 유의수준 5%에서 귀무가설을 기각할 수 없다. 잔차 분산은 0.0005665로 추정되었다.

<표 11> ARIMA(2,1,2)모형에 대한 계수 추정 및 유의성 검정 결과

	Estimate	std.Error	Z value	Pr(>|z|)
ar1	-0.250082	0.358525	-0.6975	0.4855
ar2	0.024659	0.534817	0.0461	0.9632
ma1	0.412888	0.356670	1.1576	0.2470
ma2	0.208957	0.548894	0.3807	0.7034

적합된 모델의 잔차가 백색 잡음 특성을 갖는지 확인하기 위해 Ljung-Box 검정을 다양한 시차에서 수행하였다. 검정 결과는 <표 12>에서 볼 수 있듯, 모든 시차(6, 12, 18, 24, 30, 36)에서 p-값은 0.05보다 크게 나타났다. 이는 잔차에 통계적으로 유의미한 자기상관이 남아 있지 않음을 의미하며, ARIMA(2,1,2) 모델이 log_plas_ts 시계열 데이터의 자기상관 구조를 적절히 포착했음을 지지한다. 그러나 모든 계수의 통계적 비유의성은 이 모델이 데이터 패턴을 설명하는 데 있어 불필요한 항들을 포함하고 있음을 시사하므로, 더 간결한 모델을 고려할 필요가 있다.

<표 11> ARIMA(2,1,2)의 Ljung-Box 결과

lags	statistic	df	p-value
6	3.063448	2	0.2161627
12	8.137482	7	0.4201571
18	16.667030	14	0.2743564
24	19.772745	20	0.4722239
30	21.005341	26	0.7416882
36	29.194950	32	0.6092474

3.2 모형 비교

앞서 진단한 ARIMA 후보 모형들 중 모형의 적합도(AIC), 계수의 통계적 유의성, 잔차의 백색 잡음 특성, 그리고 미래 예측의 합리적인 패턴을 종합적으로 고려하여 최적 모형을 도출하였다.

각 후보 모형의 AIC 값, 계수 유의성, 잔차 검정 결과 및 예측 패턴 특성을 종합하여 <표 13>에 제시하였다. AIC는 모형의 복잡도에 페널티를 부과하여 과적합을 방지하고 예측 성능이 우수한 모형을 선택하는 데 활용되는 지표이며, 값이 낮을수록 상대적으로 우수한 모형으로 간주한다. 모든 모형은 Ljung-Box 검정 결과 잔차가 백색 잡음 특성을 가지는 것으로 확인되어, 기본적인 통계적 적합성은 충족하였다.

<표 13>에서 확인할 수 있듯이, AIC 측면에서는 ARIMA(0,1,2) 모형이 -1217.64로 가장 낮은 값을 기록하여 가장 우수한 것으로 나타났다. 다음으로는 ARIMA(2,1,0) 모형이 -1216.85로 두 번째로 낮은 AIC 값을 보였다.

계수의 통계적 유의성 측면에서는 ARIMA(0,1,2), ARIMA(1,1,1), ARIMA(2,1,0) 모형이 모든 계수들이 통계적으로 유의미하여 모형의 간결성 및 설명력 측면에서 우수성을 보였다. 특히 ARIMA(0,1,2) 모형의 모든 MA 계수와 ARIMA(2,1,0) 모형의 모든 AR 계수는 0.05 유의수준 하에서 통계적으로 유의미하였다. 반면, 나머지 모형들에서는 하나 이상의 계수가 통계적으로 유의미하지 않게 나타나, 모형에 불필요한 항들이 포함되어 있음을 시사한다.

<표 13> 잠정적 모형 비교 결과

모형	AIC	계수 유의성	파라미터 수
ARIMA(0,1,2)	-1217.64	MA(1): 유의, MA(2): 유의	2
ARIMA(1,1,1)	-1213.51	AR(1): 유의, MA(1): 유의	2
ARIMA(1,1,2)	-1216.35	AR(1): 비유의, MA(1): 비유의, MA(2): 유의	3
ARIMA(2,1.0)	-1216.85	AR(1): 유의, AR(2): 유의	2
ARIMA(2,1,1)	-1216.08	AR(1): 비유의, AR(2): 유의, MA(1): 비유의	3
ARIMA(2,1,2)	-1214.35	모든 계수 비유의	4

3.3 최종 모형 선택

종합적인 평가 결과, AIC 값이 가장 낮고 모든 계수가 유의미하며 잔차 특성도 만족하는 ARIMA(0,1,2) 모형과, AIC 값은 미세하게 높지만 모든 계수가 유의미하고 잔차 특성 만족 및 장기 예측 패턴의 현실성이 더 높은 ARIMA(2,1,0) 모형을 최종 후보로 선정하였다. 두 모형의 잔차 정규성 또한 <그림 5>의 Q-Q Plot을 통해 시각적으로 확인할 수 있으며, 이는 모형의 통계적 가정 충족을 보여준다.

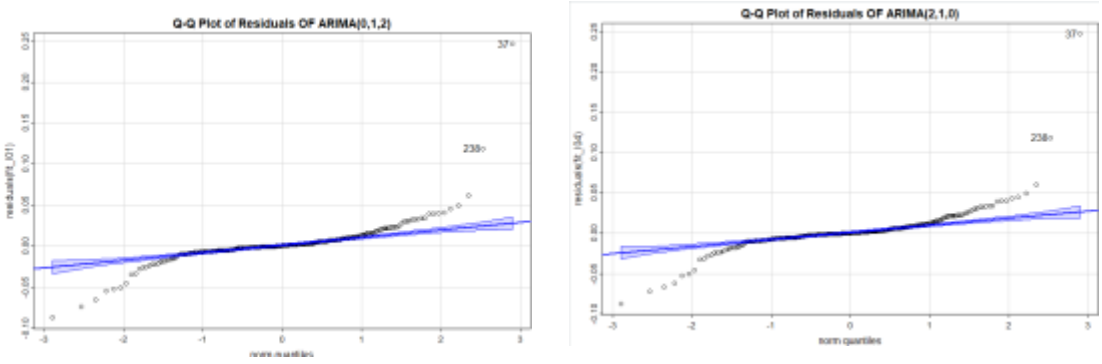

<그림 5> ARIMA(0,1,2)의 QQ-PLOT(왼쪽). ARIMA(2,1,0)의 QQ-PLOT(오른쪽)

ARIMA(0,1,2) 모형은 MA 모델의 특성상 장기 예측 시 포인트 예측값이 특정 값으로 고정되는 현상을 보였다. 이는 데이터가 장기적으로 뚜렷한 추세 없이 특정 수준으로 수렴한다는 모델의 판단을 의미한다. 반면, ARIMA(2,1,0) 모형은 AR 항을 포함하고 있어 장기 예측 시에도 포인트 예측값이 고정되지 않고 미세하게나마 지속적으로 변화하는 패턴을 나타낼 수 있다. 이러한 특성은 현실의 시계열 데이터가 장기적으로 완전히 정체되기보다는, 과거의 자기

상관 구조에 기반하여 미세한 변동성을 유지할 가능성을 더 잘 반영할 수 있다.

두 모형 모두 통계적 적합성을 만족하지만, 예측 결과의 해석과 현실 반영에 있어 상이한 특성을 보이므로, 각 모형의 예측 결과를 자세히 살펴보고 가장 적합한 최종 예측 모형을 선택하고자 한다.

4. …… 결과

흐를수록 95% 신뢰구간이 점차 넓어지는 것을 확인할 수 있다.

5. 결론

…… 보고 미래를 예측해 보았다. 그 결과, 본 데이터는 이상 데이터 한 부분을 빼고는 평균과 분산이 일정한 정상시계열로 판단되었고, 분석 결과 AR(3)모형이 가장 적절한 모형으로 나왔다.

참고 문헌

최다연, 김승진 and 이인석. (2024). ESG 경영과 유한킴벌리의 ESG 실천 사례 : 자원순환경제 중심으로. 문화교류와 다문화교육, 13(1), 577-599.